



HANSHIN
UNIVERSITY

소프트웨어융합학부
202155011 송영욱

코드 문제점 분석 및 오류 해결

```
""" 보스턴 주택 가격 예측 - 선형 회귀 분석
    정답 코드 및에 오답 코드 적었습니다 """

""" CSV 파일 분석 """
# [0]  CRIM      : 자치시(town) 별 1인당 범죄율
# [1]  ZN        : 25,000 평방피트를 초과하는 거주지역의 비율
# [2]  INDUS     : 비소매상업지역이 점유하고 있는 토지의 비율
# [3]  CHAS      : 찰스강에 대한 더미변수(강의 경계에 위치한 경우는 1, 아니면 0)
# [4]  NOX       : 10ppm 당 농축 일산화질소
# [5]  RM        : 주택 1가구당 평균 방의 개수
# [6]  AGE       : 1940년 이전에 건축된 소유주택의 비율
# [7]  DIS       : 5개의 보스턴 직업센터까지의 접근성 지수
# [8]  RAD       : 방사형 도로까지의 접근성 지수
# [9]  TAX       : 10,000 달러 당 재산세율
# [10] PTRATIO   : 자치시(town)별 학생/교사 비율
# [11] LSTAT     : 모집단의 하위계층의 비율(%)
# [12] MEDV      : 본인 소유의 주택가격(중앙값) (단위: $1,000)
# [13] CAT.MEDV  : 잘모르는값

import pandas as pd
file_path = "Boston_Housing.csv"
#file_path = "BostonHousing.csv" #파일 이름 틀림

HomeDataDirectory = 'Data/'
# HomeDataDirectory = 'Data' #파일 디렉토리 로드 실패

Data_file_path = HomeDataDirectory + file_path

df_data = pd.read_csv(Data_file_path) #FILLE NOT FOUND ERROR

print(df_data.shape)

#%/%
```

```

import numpy as np

bh_data = np.array(df_data.values, dtype=np.float32)
#float값을 base로 하기 때문에 값을 변경해줘야한다.

x_train = np.array(bh_data[:400,:12], dtype=np.float32)
# 문제의 오류 인덱스 0 ~ 11까지
#x_train = np.array(bh_data[:400,:13], dtype=np.float32)
#학습데이터에 12열인 답이 포함 되어 있어서 답을 다알고 학습하는 문제가 생김

y_train = np.array(bh_data[:400,12:13], dtype=np.float32)
#학습데이터 정답 값 12열 사용
#y_train = np.array(bh_data[:400,12], dtype=np.float32)
#CSV파일 확인결과 MEDV는 인덱스 12열에 존재함 그래서 그값을 바탕으로 수정

x_test = np.array(bh_data[400:,:12], dtype=np.float32)
# test도 인덱스 0 ~ 11까지
#test 데이터에도 답이 포함되어 있어서 답을 다알고 테스트하는 문제가 생김
#x_test = np.array(bh_data[400:,:13], dtype=np.float32)

y_test = np.array(bh_data[400:,12:13], dtype=np.float32)
# 테스트 데이터의 12열의 정답 설정
#y_test = np.array(bh_data[400:,12], dtype=np.float32)

print(x_train.shape, y_train.shape, x_test.shape, y_test.shape)

# ###
from sklearn.linear_model import LinearRegression
lr = LinearRegression()

lr.fit(x_train, y_train)
#lr.fit(x_train, y_train.T) y_Train값이 나와야함 (train 학습값의 정답임)

y_pred = lr.predict(x_test)

```

```

# MSE(평균제곱오차) 출력 오차가 하나도 없는 문제 생겨서
# 어디서 틀렸는지 확인 하려고 MSE값을 확인함

from sklearn.metrics import mean_squared_error
test_mse = mean_squared_error(y_test, y_pred)
print(f"테스트 MSE: {test_mse:.4f}")
#%%

import matplotlib.pyplot as plt
plt.close("all")
plt.title("실제 값 vs 예측 값")
plt.plot(y_test, 'r', label='실제 값')
plt.plot(y_pred, 'b', label='예측 값')
#plt.plot(y_pred, 'r', label='실제 값') 색이 반대임
#plt.plot(y_test, 'b', label='예측 값') 색이 반대임
plt.show()

```

최종 결과

